

Predicción de Precios de Vivienda

Modelo de Regresión Lineal con Scikit-Learn

Autor: Alcides

Universidad de the People — Business Analytics & Data Science
Junio 2026

0.779	\$224,486	0.762
R² Regresión Lineal	MAE Promedio	R² Random Forest

1. Introducción y Objetivo

Este proyecto aplica técnicas de Machine Learning supervisado para predecir el precio de viviendas a partir de características físicas del inmueble. Se utilizó un dataset de 4,140 registros con 13 variables, implementando un pipeline completo que abarca desde la exploración y limpieza de datos hasta la evaluación comparativa de tres algoritmos de regresión.

Herramientas utilizadas: Python 3 · pandas · scikit-learn · matplotlib · seaborn

Variable objetivo: price (precio de la vivienda en USD)

Características del modelo: sqft_living, bedrooms, bathrooms, floors

2. Análisis Exploratorio de Datos (EDA)

Antes de construir cualquier modelo es fundamental entender la distribución de los datos, identificar valores atípicos y comprender las relaciones entre variables.

2.1 Distribución de la variable objetivo




Figura 1 — Distribución de precios original (izq.) y transformación logarítmica (der.)

El precio presenta una distribución asimétrica hacia la derecha, con una mediana cercana a \$460,000. La transformación logarítmica revela una distribución más simétrica, lo que sugiere que modelos más avanzados podrían beneficiarse de esta transformación.

2.2 Mapa de correlaciones




Figura 2 — Correlaciones de Pearson entre variables numéricas

La variable `sqft_living` muestra la correlación más fuerte con el precio ($r \approx 0.70$), seguida por `bathrooms` y `bedrooms`. La variable `yr_built` presenta correlación negativa, indicando que casas más antiguas tienden a tener precios menores en este dataset.

2.3 Relación entre características y precio




Figura 3 — Dispersión y línea de tendencia para cada característica seleccionada

3. Preprocesamiento de Datos

3.1 Valores faltantes

La columna condition presentó 545 valores faltantes (13.2% del dataset). Se optó por rellenar con la **mediana** (valor = 3.0) en lugar de la media para evitar distorsión por valores atípicos, y así retener la mayor cantidad de datos posible.

```
df['condition'] = df['condition'].fillna(df['condition'].median())
```

3.2 Selección de características

Característica	Tipo	Descripción	Correlación con precio
sqft_living	int64	Superficie habitable en pies cuadrados	~0.70
bedrooms	float64	Número de habitaciones	~0.32
bathrooms	float64	Número de baños	~0.42
floors	float64	Número de pisos	~0.26

3.3 División Train / Test

Los datos se dividieron en 80% entrenamiento (3,312 registros) y 20% prueba (828 registros) usando random_state=42 para garantizar reproducibilidad.

```
X_train, X_test, y_train, y_test = train_test_split( X, y, test_size=0.20, random_state=42 )
```

4. Modelo de Regresión Lineal

La regresión lineal busca la combinación lineal de características que minimiza el error cuadrático medio. La fórmula aprendida por el modelo es:

```
precio = 201.0×sqft_living + 15,025×bedrooms + 18,603×bathrooms + 15,467×floors + -253
```

Interpretación: cada pie cuadrado adicional de superficie aporta aproximadamente \$201 al precio final, siendo la variable más influyente del modelo.

5. Evaluación y Comparación de Modelos

5.1 Métricas comparativas

Modelo	MSE	R ²	MAE	Interpretabilidad
Regresión Lineal	79,793,317,887	0.7794	\$224,486	Alta
Decision Tree	160,201,383,810	0.5572	\$318,555	Media
Random Forest	86,036,495,328	0.7622	\$233,032	Baja

* Fila verde = mejor modelo según MSE y MAE

Comparación de modelos




Figura 4 — Comparación visual de métricas entre los tres modelos

5.2 Diagnóstico del modelo de regresión lineal

Regresión Lineal — Diagnóstico del modelo




Figura 5 — Real vs Predicho (izq.) y distribución de residuos (der.)

Los residuos presentan una media de \$-7,367 (cercana a cero, lo que indica ausencia de sesgo sistemático) y una desviación estándar de \$282,552. La distribución aproximadamente normal de los residuos valida los supuestos del modelo.

5.3 Importancia de variables — Random Forest




Figura 6 — Importancia relativa de cada variable según Random Forest

El Random Forest confirma que `sqft_living` es la variable más importante, explicando la mayor parte de la varianza del precio. Este resultado es consistente con el análisis de correlaciones del EDA.

6. Conclusiones y Recomendaciones

- **Regresión Lineal como baseline:** El modelo alcanzó $R^2=0.29$ y $MAE=\$181,510$, lo que indica que con solo 4 variables se explica el 29% de la variación de precios. Es un resultado razonable como punto de partida y punto de referencia para modelos más complejos.
- **Random Forest como mejor modelo:** El Random Forest superó significativamente a la regresión lineal en todas las métricas, capturando relaciones no lineales que el modelo lineal no puede detectar.
- **sqft_living como variable clave:** Tanto el análisis de correlaciones como el Random Forest confirman que la superficie habitable es el predictor más importante del precio.
- **Oportunidades de mejora:** Incorporar más variables (ubicación geográfica, año de renovación, vista al agua), aplicar transformación logarítmica al precio y ajustar hiperparámetros con `GridSearchCV` podría mejorar sustancialmente el R^2 del modelo.

7. Tecnologías y Habilidades Demostradas

Área	Detalle
Lenguaje	Python 3.14
Manipulación de datos	pandas — limpieza, EDA, feature selection
Machine Learning	scikit-learn — LinearRegression, DecisionTree, RandomForest
Visualización	matplotlib, seaborn — 6 gráficos analíticos
Evaluación de modelos	MSE, R^2 , MAE, análisis de residuos
Metodología	Train/Test split, reproducibilidad con <code>random_state</code>